

Fonds européens de cohésion en Île-de-France

Étude de cas SGAE — méthodologie et outils

15 septembre 2026

1. Outils

Outil	Version	Usage
Python	3.13.15	Traitement de toute la chaîne
pandas	3.0.5	Chargement, jointures, agrégations, corrélations
matplotlib	3.11.2	Les 4 figures, en PNG (aucune dépendance en ligne)
openpyxl	3.1.5	Lecture des classeurs .xlsx (INSEE, fichier 21-27)
uv	—	Environnement virtuel et dépendances
pandoc + XeLaTeX	3.10.2	Conversion des deux markdown en PDF
Claude Code (Opus 5)	—	Assistant de développement : exploration des schémas, écriture et débogage des scripts, rédaction sous revue humaine

scipy a été volontairement écarté : la corrélation de Spearman est obtenue par un Pearson sur les rangs, soit trois lignes de code et une dépendance de moins. **Aucun traitement manuel en tableur : tous les chiffres des deux documents sortent des scripts**, donc rejouables et vérifiables.

2. Sources

- **Opérations 2014-2020** — export JSON de l'API Opendata de la Région Île-de-France (jeu référencé sur data.gouv.fr). 1 121 opérations, source mise à jour le 03/05/2022.
- **Revenus communaux** — INSEE, FiLoSoFi 2017, fichier communal. 1 260 communes franciliennes après exclusion des arrondissements parisiens.
- **Opérations 2021-2027** — fichier national FEDER-FSE+-FTJ d'europe-en-france.gouv.fr, version du 08/09/2025. 5 148 opérations toutes régions.

Toutes récupérées le 15/09/2026 à 10 :15 ; URL exactes dans `src/telecharger.py`, journal horodaté dans `sorties/journal_telechargement.md`.

Deux choix de fichier à signaler :

- **JSON plutôt que CSV** pour 14-20 : le champ département est multivalué ; le CSV l'aplatit en une chaîne dont le séparateur doit être deviné, le JSON le restitue comme une liste.
- **Revenus déclarés (FIL02017_DEC_COM) plutôt que disponibles** : la question porte sur les *foyers fiscaux*, donc sur le revenu déclaré avant redistribution. Indicateur Q217, onglet ENSEMBLE, à partir de la 6^e ligne (les 5 premières sont un en-tête de présentation).

3. Chaîne de traitement

data/ (3 sources brutes)

```
|
|— src/telecharger.py ..... récupération + journal (URL, taille, date)
|— src/commun.py ..... socle : renommage des 13 colonnes, montant UE,
|                          normalisation des codes département, éclatement
|                          multivalué, normalisation des libellés de communes
|— src/q1_analyse.py ..... top 10, groupement départemental, croisement INSEE
|— src/q2_qualite.py ..... complétude et anomalies mesurées
|— src/q3_feder.py ..... départements FEDER et montant moyen
|— src/q4_evolution.py ..... comparaison 14-20 / 21-27 et figures
|
|   ↳ sorties/ ..... un .md et un .csv par tableau, un .png par figure
```

Les quatre scripts d'analyse sont **indépendants** et s'exécutent seuls. `commun.py` existe parce que le chargement a quatre appelants réels, sans abstraction spéculative. Chaque tableau est écrit en markdown **et** en CSV, ce qui garantit qu'aucun chiffre des livrables n'a été recopié à la main.

4. Conventions de calcul

Le jeu 2014-2020 ne permet pas de répondre sans ces conventions, et deux analystes en retenant d'autres obtiendraient d'autres chiffres. D'où leur énoncé explicite, avec leur effet chiffré.

4.1 Le montant UE est reconstitué

Aucune des 13 colonnes ne donne la subvention européenne. On pose :

montant UE = total des dépenses éligibles × taux de cofinancement UE

Soit 693,2 M€ pour 1 668,9 M€ de dépenses éligibles — cohérent avec les « plus de 600 M€ » annoncés dans la description du jeu, ce qui valide la formule.

4.2 Département multivalué : comptage intégral, montant au prorata

Le champ est une **liste** (une opération régionale porte les huit départements) :

- **nombre d'opérations** : comptée dans **chacun** des départements cités — d'où 2 241 rattachements franciliens pour 1 121 opérations;
- **montant** : **divisé à parts égales** entre les départements cités, de sorte que la somme des départements égale le total régional localisé. Écart contrôlé à chaque exécution : **0,0000 €**.

Les codes sont dédoublonnés après suppression des zéros de tête (une opération porte 75 **et** 075, sinon Paris compte double). En revanche **aucun code erroné n'est corrigé** (2, 3, 3.2153009259259258, 97) : le faire supposerait de réécrire la source sur hypothèse. Ils sont recensés et isolés hors Île-de-France.

4.3 Appariement INSEE par libellé, sans forçage

Le jeu n'a **aucun code commune**. Procédure : éclatement de la localisation sur « : », puis normalisation des deux côtés (majuscules, sans accent, tirets et apostrophes en espaces), puis jointure sur le référentiel francilien, puis répartition du montant à parts égales entre les libellés cités.

Deux garde-fous : les **4 homonymes franciliens** (Blandy, Marolles-en-Brie, Mondreville, Saint-Martin-des-Champs) sont écartés faute de pouvoir les départager; les localisations **non communales ne sont pas rattachées de force**, elles sont comptées puis exclues.

Couverture obtenue : 287 communes, 610 opérations, mais **26,0 % du montant UE** — chiffre affiché dans les résultats plutôt que dissimulé derrière un coefficient.

4.4 Quatre coefficients de corrélation, pas un

Un coefficient unique aurait été trompeur. Deux périmètres (communes financées / toutes les communes, celles sans opération valant zéro) × deux variables (montant total / montant par habitant) × Pearson et Spearman. L'écart entre Pearson (−0,07) et Spearman (−0,42) est lui-même une information : la distribution est trop asymétrique pour que Pearson soit pertinent. Le montant par habitant est indispensable, sans quoi la corrélation mesure surtout la taille démographique.

4.5 Méthode de production des restitutions de la question 4

Comparer une programmation avancée (liste arrêtée en mai 2022) à une programmation jeune (septembre 2025) exige deux précautions :

1. **Alignement sur l'année de programmation** : l'année de début de chaque opération devient un rang (année 1 = 2014 ou 2021), puis les montants sont cumulés. La comparaison n'est tenue pour licite que **jusqu'à la 4^e année**. Au-delà, la courbe 21-27 est **interrompue** sur le graphique — la prolonger à plat aurait suggéré un arrêt de la programmation.
2. **Priorité aux indicateurs insensibles au stade d'avancement** : médiane et moyenne par opération, taux de cofinancement, répartition par fonds. Ils restent interprétables même sur des listes incomplètes, contrairement aux totaux.

Trois figures en découlent : volumes par fonds (barres groupées), cumul à millésime identique (courbes), distribution du montant par opération (boîtes à moustaches, extrêmes masqués, moyenne en losange). Toutes en PNG, intégrées aux PDF, sans dépendance en ligne.

Le périmètre 21-27 est le seul programme régional francilien du fichier national (« Programme régional Île-de-France et bassin de la Seine FEDER-FSE+ 2021-2027 », 140 opérations sur 5 148) ; une assertion arrête le script si le filtre en capturerait plusieurs.

5. Contrôles exécutés

Chaque script imprime ses contrôles ; un échec interrompt le traitement. Journal complet dans sorties/journal_execution.txt.

Contrôle	Résultat
Nombre d'opérations chargées	1 121, conforme à l'API
Répartition par fonds recoupée avec les facettes de l'API	FSE 787 / FEDER 313 / IEJ 21, conforme
Conservation du montant après prorata (assertion)	écart 0,0000 €
Montant UE total vs description de la source	693,2 M€ vs « plus de 600 M€ », cohérent
Effectifs FEDER par département vs comptage brut (assertion)	conforme
Robustesse du classement Q3 à la convention	même trio en mono-départemental
Codes INSEE retenus tous franciliens	vérifié par filtre
Taux d'appariement affiché, non appariés comptés	287 communes, 26,0 % du montant
Unicité du programme régional 21-27 (assertion)	un seul libellé

6. Reproduire

```
uv venv --python 3.13 .venv
uv pip install -r requirements.txt
```

```
.venv/bin/python src/telecharger.py      # ~59 Mo, quelques minutes
.venv/bin/python src/commun.py           # contrôles du socle
.venv/bin/python src/q1_analyse.py
.venv/bin/python src/q2_qualite.py
.venv/bin/python src/q3_feder.py
.venv/bin/python src/q4_evolution.py
```

```
pandoc RESULTATS.md -o RESULTATS.pdf --pdf-engine=xelatex \
-V lang=fr -V geometry:margin=2cm -V fontsize=10pt \
-V mainfont="Helvetica Neue" -V monofont="Menlo"
```

Les sources brutes (59 Mo) ne sont pas jointes : `src/telecharger.py` les récupère à l'identique.

7. Arbitrages assumés

1. **Aucune valeur erronée corrigée.** Lire 3 comme 93 au vu de la localisation « SAINT DENIS » serait probablement juste, mais introduirait une hypothèse non tracée dans les chiffres publiés.
2. **La répartition à parts égales est une convention, pas une mesure.** Une clé à la population serait plus réaliste, mais rien dans le jeu n'indique la localisation réelle de la dépense : ce serait une fausse précision.
3. **Pas d'appariement phonétique** des communes : il aurait amélioré la couverture au prix d'erreurs invérifiables. Une couverture honnête de 26 % est préférée à une couverture optimiste.
4. **La question 4 mesure des volumes publiés, pas des taux d'absorption** : les dotations programmées sont absentes des deux fichiers et exigeraient une troisième source.
5. **La question 1 a été traitée à la maille demandée tout en signalant qu'elle n'est pas la bonne.** Une lecture départementale serait plus solide ; une lecture par catégorie d'intervention serait la plus pertinente, mais reste impossible (champ renseigné à 20,1 %).

Ordre de traitement retenu pour qu'un rendu interrompu reste cohérent : socle et contrôles, puis question 3 (la plus directe), questions 1 et 2 qui partagent ce socle, enfin question 4 qui mobilise une source supplémentaire. Les deux documents ont été rédigés au fil des résultats.